

# Web Developer Gera #3

Donnerstag, 7. November 2019

# Über mich

- Johannes
- 34
- aus Gera
- Fachinformatiker für Systemintegration
- Bachelor Betriebliche IT-Systeme
- Master Informatik
- Arbeite seit mehreren Jahren als Webentwickler

# Elsterkind GmbH

- Digitalagentur
- Online Marketing, Ads, Affiliate, Analytics, Webentwicklung...
- 2018 in Leipzig gegründet
- 10 Mitarbeiter + 6 Freelancer

# Triple Stores, DBpedia & SPARQL

Thema

# Disclaimer

Dieser Vortrag soll **informativ** sein und gegebenenfalls **Interesse für das Thema wecken**.

Ich bin darin **kein Profi**. Ich benutze das aktuell **nicht produktiv**. Ich verfolge nicht aktiv die Entwicklung der vorgestellten Techniken. ABER ich finde das Thema spannend.

Fragen werden nach **bestem Wissen und Gewissen** beantwortet.

# Agenda

- Triple Store Datenbanken
- Projekt DBpedia
- Intro SPARQL mit Anwendungsbeispiel

# Triple Stores



# Triple Store

- Wikipedia:
    - Ein Tripelspeicher oder RDF-Speicher (RDF = Resource Description Framework) ist eine speziell entwickelte Datenbank für das Speichern und Abrufen von Tripeln durch semantische Abfragen.
  - Triple:
    - Datenentität, die aus Subjekt, Prädikat und Objekt besteht
- Wer → Hat → Was



# Aufbau eines Triples 1/2

- **Subjekt:**
  - Das Element, über das eine Aussage getroffen wird
- **Prädikat:**
  - Die Eigenschaft, über die eine Aussage getroffen wird
- **Objekt:**
  - Der Wert, den die Eigenschaft bekommt

# Aufbau eines Triples

- **Subjekt:**
  - **Beispiel:** Das Kutscherhaus Gera
- **Prädikat:**
  - **Beispiel:** liegt am
- **Objekt:**
  - **Beispiel:** Mühlgraben

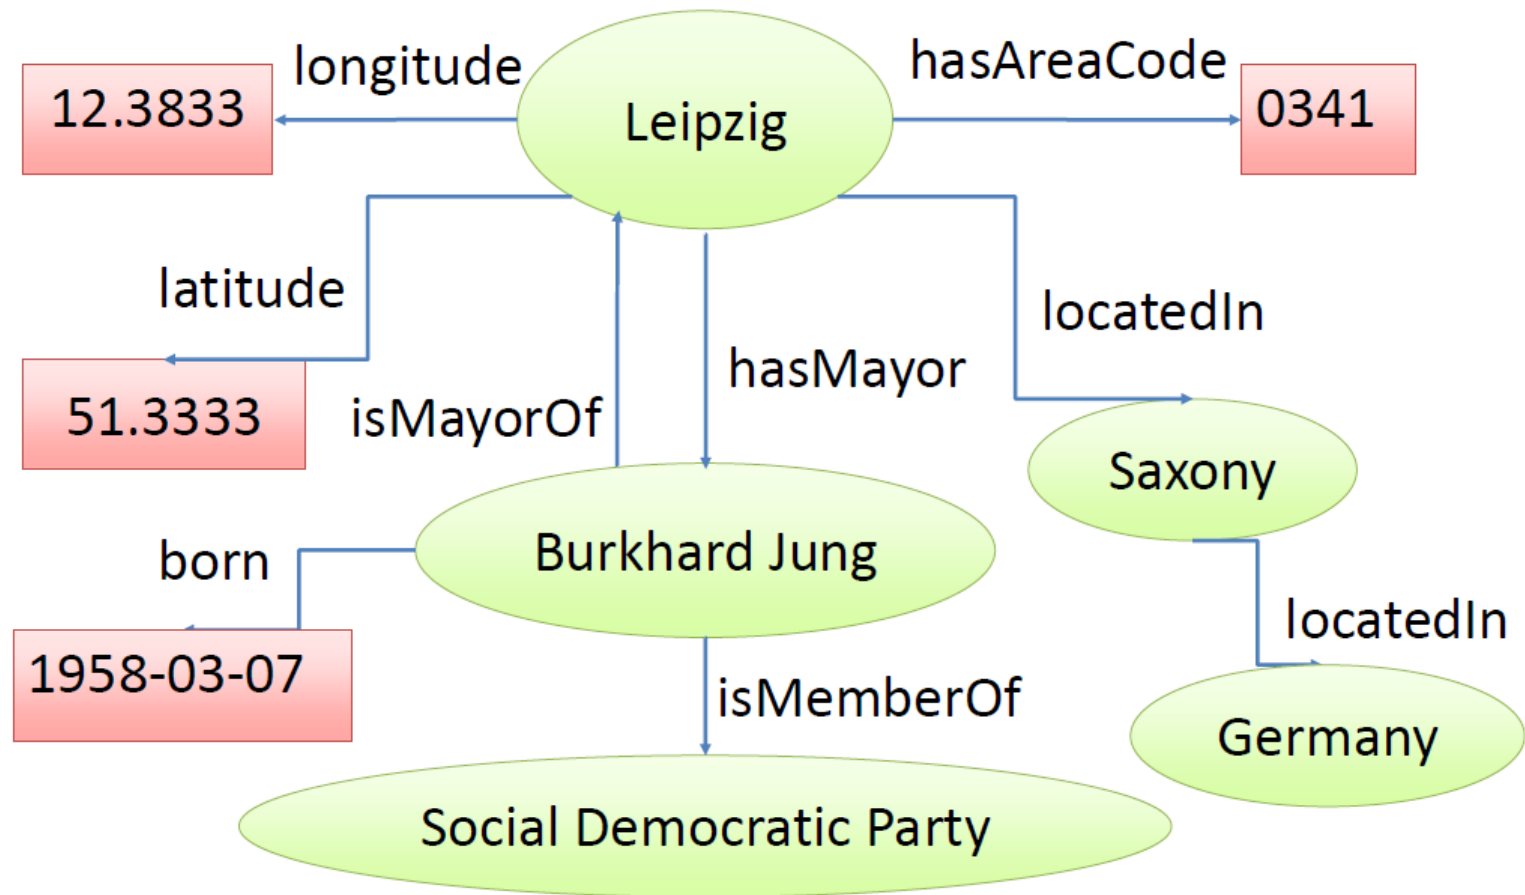
# Aufbau eines Triples 2/2

- Die einzelnen Attribute werden mit URIs gekennzeichnet
  - **URI = Uniform Resource Identifier**
- Ähnlich zu URLs, aber muss nicht auf ein Webdokument zeigen
- Dienen zur weltweit eindeutigen Bezeichnung von Ressourcen
- Beispiel: `http://gera.de/orte/Kutscherhaus`

# Aufbau eines Triples

- **Subjekt:**
  - **Beispiel:** Das Kutscherhaus Gera
  - **URI:** <<http://gera.de/orte/Kutscherhaus>>
- **Prädikat:**
  - **Beispiel:** liegt am
  - **URI:** <[http://gera.de/geo/liegt\\_am](http://gera.de/geo/liegt_am)>
- **Objekt:**
  - **Beispiel:** Mühlgraben
  - **URI:** <<http://gera.de/gewässer/Mühlgraben>>

# RDF Graph



# Ontologie

- Die Definition eines solchen Graphen, wird Ontologie bezeichnet
- Dies ähnelt einem Datenbankschema
  - Ort hat Longitude und Latitude als Literal
  - Ort hat Bürgermeister als Objekt
  - Bürgermeister hat Name als String
  - usw. usw.
- Auch können Regeln für diese Schemata festgelegt werden
  - Ort hat nur 1 Bürgermeister
  - Latitude und Longitude müssen Float sein
  - Es kann mehrere Orte geben

# Notation

- Es gibt verschiedene Möglichkeiten Triple-Daten zu definieren
- Eine einfache Notation ist die Turtle Syntax

```
@prefix rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns#> .  
@prefix rdfs: <http://www.w3.org/2000/01/rdf-schema#> .  
@prefix xsd: <http://www.w3.org/2001/XMLSchema#> .  
@prefix dbr: <http://dbpedia.org/resource/> .  
@prefix dbp: <http://dbpedia.org/property/> .  
@prefix geo: <http://www.w3.org/2003/01/geo/wgs84_pos#> .
```

dbr:Leipzig	dbp:hasMayor	dbr:Burkhard_Jung .
dbr:Leipzig	rdfs:label	"Leipzig"@de .
dbr:Leipzig	geo:lat	"51.333332"^^xsd:float .
dbr:Leipzig	geo:long	"12.383333"^^xsd:float .

# Zusammenfassung

- Speicherung semantischer Daten
- Subjekt → Prädikat → Objekt
- Schema definiert Struktur
- Adressierung mit Hilfe von URIs
- Objekte können URIs oder Literale sein



# DBpedia




# DBpedia



- 2007 ins Leben gerufen
- Unter anderem von der Uni Leipzig
- Gemeinschaftsprojekt verschiedener Einrichtungen
- Ziel:
  - Wikipedia-Artikel nach den Konzepten von **Linked Open Data** für das **Semantic Web** transformieren

- Einfach gesagt:
  - Man nehme Wikipedia-Artikel und forme die Informationen so um, dass die Daten strukturiert und maschinenlesbar abgerufen werden können.




**InfAI**<sup>®</sup>

Institut für Angewandte Informatik

**FIZ Karlsruhe**

Leibniz-Institut für Informationsinfrastruktur

**Fraunhofer****IAIS****OPEN KNOWLEDGE  
FOUNDATION****SEMANTIC WEB COMPANY****Linked Open Data Initiative**  
LinkedOpenData.jp ★★★★★**TIB**LEIBNIZ-INFORMATIONSZENTRUM  
TECHNIK UND NATURWISSENSCHAFTEN  
UNIVERSITÄTSBIBLIOTHEK**Knowledge Graph**<sup>™</sup>

# Datenbasis

- Als Datenbasis dienen **nicht** die Fließtexte
- Ausgewertet werden:
  - Infoboxen, Tabellen, geographische Daten, Weblinks, etc.
- Die extrahierten Daten werden als RDF-Daten gespeichert
- Die RDF-Datenbank wird in längeren Abständen aus Wikipedia Daten neu erstellt

Wappen	Deutschlandkarte
	
Basisdaten	
Bundesland:	Thüringen
Höhe:	194 m ü. NHN
Fläche:	152,19 km <sup>2</sup>
Einwohner:	94.152 (31. Dez. 2018) <sup>[1]</sup>
Bevölkerungsdichte:	619 Einwohner je km <sup>2</sup>
Postleitzahlen:	07545–07557
Vorwahlen:	0365, 036695
Kfz-Kennzeichen:	G
Gemeineschlüssel:	16 0 52 000
Stadtgliederung:	40 Stadtteile
Adresse der Stadtverwaltung:	Kornmarkt 12 07545 Gera

# Deutsches DBpedia

- Projektseite: <http://de.dbpedia.org/>
- Deutsche Live-Datenbasis leider aktuell nicht verfügbar ☹
- Vortrag vom 12.09.2019 - 14th DBpedia Community Meeting
  - „The Return of German DBpedia“
  - Man will wieder aktiv(er) an dem Projekt arbeiten
  - Verbesserung der deutschen Extraktionsdaten
  - Suche nach aktiven Mitgliedern/Unterstützung
  - Deutsches Wikipedia ist das 4. größte weltweit

# DBpedia Datenbasis (2016-10 de)

Anzahl von Triplen	104.989.619
Anzahl von Entitäten (owl:Thing)	1.374.894
Anzahl von Personen (dbo:person)	627.264
Anzahl von Organisationen (dbo:organizations)	62.054
Anzahl von Orten (dbo:locations)	406.943
Mapped Templates	17,48 %
Mapped Properties	7,21 %

# SPARQL





# SPARQL

- Wikipedia:
  - SPARQL ist eine graphenbasierte Abfragesprache für RDF. Der Name ist ein rekursives Akronym für SPARQL Protocol and RDF Query Language.
- 2008 W3C-Standard
- Grobe Struktur ähnlich SQL

# Arten von SPARQL Anfragen

- **SELECT**
  - Gibt eine Tabelle mit Daten aus, die die Bedingungen erfüllen
- **CONSTRUCT**
  - Wie SELECT, nur setzt Daten in neuer Form zusammen
- **DESCRIBE**
  - Gibt alle Anweisungen im Datensatz aus
- **ASK**
  - Prüft, ob es Daten gibt, die einem SELECT entsprechen

# Struktur

- **PREFIX**
  - Definitionen von Präfixen, die in der Anfrage benutzt werden (ähnlich Namespaces)
- **SELECT/...**
  - Anfragetyp, was gesucht wird
- **WHERE**
  - Filter der Anfrage
- **Dazu noch:**
  - **FILTER, ORDER, LIMIT, OFFSET, ...**

# SPARQL Beispiel

- Einfaches Anwendungsbeispiel
- Nachvollziehbar auf <http://dbpedia.org/sparql/>
  - Einfach Query Text einfügen und „Run Query“ ausführen
- Hinweis:
  - Die genutzten Prefixe sind vordefinierte Prefixe für die genutzte Ontologie. Daher müssen die hier nicht explizit definiert werden

# SPARQL Beispiel

```
SELECT ?person
WHERE {
    ?person dbo:birthPlace dbr:Gera .
}
LIMIT 10
```

# SPARQL Beispiel

<b>person</b>
<a href="http://dbpedia.org/resource/Max_Frankel">http://dbpedia.org/resource/Max_Frankel</a>
<a href="http://dbpedia.org/resource/Konrad_Weise">http://dbpedia.org/resource/Konrad_Weise</a>
<a href="http://dbpedia.org/resource/Tina_Liebig">http://dbpedia.org/resource/Tina_Liebig</a>
<a href="http://dbpedia.org/resource/Thomas_Blaschek">http://dbpedia.org/resource/Thomas_Blaschek</a>
<a href="http://dbpedia.org/resource/Jürgen_Simon">http://dbpedia.org/resource/Jürgen_Simon</a>
<a href="http://dbpedia.org/resource/Erik_Balnuweit">http://dbpedia.org/resource/Erik_Balnuweit</a>
<a href="http://dbpedia.org/resource/Prince_Heinrich_VIII_Reuss_of_Köstritz">http://dbpedia.org/resource/Prince_Heinrich_VIII_Reuss_of_Köstritz</a>
<a href="http://dbpedia.org/resource/Helga_Königsdorf">http://dbpedia.org/resource/Helga_Königsdorf</a>
<a href="http://dbpedia.org/resource/Dietrich_Peltz">http://dbpedia.org/resource/Dietrich_Peltz</a>
<a href="http://dbpedia.org/resource/Heike_Drechsler">http://dbpedia.org/resource/Heike_Drechsler</a>

# SPARQL Beispiel

```
SELECT ?person
WHERE {
    ?person dbo:birthPlace dbr:Gera .
    ?person foaf:gender "female"@en .
}
LIMIT 10
```

# SPARQL Beispiel

<b>person</b>
<a href="http://dbpedia.org/resource/Tina_Liebig">http://dbpedia.org/resource/Tina_Liebig</a>
<a href="http://dbpedia.org/resource/Helga_Königsdorf">http://dbpedia.org/resource/Helga_Königsdorf</a>
<a href="http://dbpedia.org/resource/Heike_Drechsler">http://dbpedia.org/resource/Heike_Drechsler</a>
<a href="http://dbpedia.org/resource/Kathrin_Zimmermann">http://dbpedia.org/resource/Kathrin_Zimmermann</a>
<a href="http://dbpedia.org/resource/Heidi_Eisenschmidt">http://dbpedia.org/resource/Heidi_Eisenschmidt</a>
<a href="http://dbpedia.org/resource/Marlies_Göhr">http://dbpedia.org/resource/Marlies_Göhr</a>
<a href="http://dbpedia.org/resource/Margitta_Pufe">http://dbpedia.org/resource/Margitta_Pufe</a>
<a href="http://dbpedia.org/resource/Patricia_Polifka">http://dbpedia.org/resource/Patricia_Polifka</a>
<a href="http://dbpedia.org/resource/Karin_Hübner">http://dbpedia.org/resource/Karin_Hübner</a>
<a href="http://dbpedia.org/resource/Bianca_Schmidt">http://dbpedia.org/resource/Bianca_Schmidt</a>



# SPARQL Beispiel

```
SELECT ?person
WHERE {
    ?person dbo:birthPlace dbr:Gera .
    ?person foaf:gender "female"@en .

    MINUS {
        ?person dbo:deathDate ?deathDate .
    }
}
LIMIT 10
```

# SPARQL Beispiel

<b>person</b>
<a href="http://dbpedia.org/resource/Tina_Liebig">http://dbpedia.org/resource/Tina_Liebig</a>
<a href="http://dbpedia.org/resource/Heike_Drechsler">http://dbpedia.org/resource/Heike_Drechsler</a>
<a href="http://dbpedia.org/resource/Kathrin_Zimmermann">http://dbpedia.org/resource/Kathrin_Zimmermann</a>
<a href="http://dbpedia.org/resource/Heidi_Eisenschmidt">http://dbpedia.org/resource/Heidi_Eisenschmidt</a>
<a href="http://dbpedia.org/resource/Marlies_Göhr">http://dbpedia.org/resource/Marlies_Göhr</a>
<a href="http://dbpedia.org/resource/Margitta_Pufe">http://dbpedia.org/resource/Margitta_Pufe</a>
<a href="http://dbpedia.org/resource/Patricia_Polifka">http://dbpedia.org/resource/Patricia_Polifka</a>
<a href="http://dbpedia.org/resource/Bianca_Schmidt">http://dbpedia.org/resource/Bianca_Schmidt</a>
<a href="http://dbpedia.org/resource/Sabrina_Schmutzler">http://dbpedia.org/resource/Sabrina_Schmutzler</a>
<a href="http://dbpedia.org/resource/Hanka_Kupfernagel">http://dbpedia.org/resource/Hanka_Kupfernagel</a>

# SPARQL Beispiel

```
SELECT ?person
WHERE {
    ?person dbo:birthPlace dbr:Gera .
    ?person foaf:gender "female"@en .
    ?person rdf:type dbo:Athlete .
    ?person dct:subject dbc:Olympic_athletes_of_East_Germany .

    MINUS {
        ?person dbo:deathDate ?deathDate .
    }
}
LIMIT 10
```

# SPARQL Beispiel

<b>person</b>
<a href="http://dbpedia.org/resource/Heike_Drechsler">http://dbpedia.org/resource/Heike_Drechsler</a>
<a href="http://dbpedia.org/resource/Margitta_Pufe">http://dbpedia.org/resource/Margitta_Pufe</a>

# SPARQL Beispiel

```
SELECT ?person, ?weight, ?height
WHERE {
    ?person dbo:birthPlace dbr:Gera .
    ?person foaf:gender "female"@en .
    ?person rdf:type dbo:Athlete .
    ?person dct:subject dbc:Olympic_athletes_of_East_Germany .
    ?person dbo:Person\weight ?weight .
    ?person dbo:Person\height ?height .
    MINUS {
        ?person dbo:deathDate ?deathDate .
    }
}
LIMIT 10
```

# SPARQL Beispiel

person	weight	height
<a href="http://dbpedia.org/resource/Heike_Drechsler">http://dbpedia.org/resource/Heike_Drechsler</a>	"68.0"^^<http://dbpedia.org/datatype/kilogram>	"181.0"^^<http://dbpedia.org/datatype/centimetre>
<a href="http://dbpedia.org/resource/Margitta_Pufe">http://dbpedia.org/resource/Margitta_Pufe</a>	"83.0"^^<http://dbpedia.org/datatype/kilogram>	"180.0"^^<http://dbpedia.org/datatype/centimetre>

# Beispiel für semantische Suchmaschine

- Fragestellung:
  - „Wie groß ist Heike Drechsler?“

```
SELECT ?height
WHERE {
    ?person rdfs:label "Heike Drechsler"@de .
    ?person dbo:Person\height ?height .
} LIMIT 1
```

height
"181.0"^^<http://dbpedia.org/datatype/centimetre>

# Beispiel für semantische Suchmaschine

- Fragestellung:
  - „Welche ist die größte Stadt Thüringens?“

```
SELECT ?city, ?population
WHERE {
    ?state rdfs:label "Thüringen"@de .
    ?city dbo:federalState ?state .
    ?city dbo:populationTotal ?population .
} ORDER BY DESC(?population)
LIMIT 1
```

city	population
<a href="http://dbpedia.org/resource/Erfurt">http://dbpedia.org/resource/Erfurt</a>	"204880"^^<http://www.w3.org/2001/XMLSchema#nonNegativeInteger>



